

프로젝트 결과 보고서

공공입찰 RFP 근거기반 질의응답 RAG 시스템

입찰메이트 (BIDAR)

팀명 우수한 김다꾸리

기간 2026-08-24 ~ 2026-09-11

팀원 홍우석(PM·평가·통합) · 박지수(데이터·청킹) · 장한빈(검색) · 김다혜(생성)

본 보고서는 프로젝트 진행 과정, 주요 성과, 발견된 문제와 개선 조치, 그리고 남은 과제를 정리한 문서입니다.
모든 수치는 측정 시점의 평가셋·채점기 버전을 함께 표기했습니다.

프로젝트 진행 중 골든셋이 여러 차례 확장·정비되면서(10문항 → 40문항 → 111문항 → 79문항 등) 각
파트·시점마다 사용한 평가셋 규모가 다르므로, 수치를 비교할 때는 반드시 함께 표기된 평가셋 종류·문항 수를
확인해야 합니다.

1. 프로젝트 개요

공공입찰 컨설턴트가 RFP(제안요청서) 문서 내용을 질문하면, 문서·페이지 근거와 함께 답변받는 RAG(검색증강생성) 시스템을 구축했다. 목표는 단순히 관련 문서를 찾는 것이 아니라, ①질문에 필요한 근거를 찾고 ②그 근거를 답변에 실제로 반영하고 ③어느 문서를 근거로 했는지 인용하는 것 세 가지다.

1.1 팀 구성 및 역할

역할	담당	주요 업무
PM · 평가 · 통합	홍우석	일정 관리, 평가 체계 설계, 팀 결과 통합
데이터 · 청킹	박지수	문서 정제, 청킹, 로컬 모델 실험, 실행 인프라
검색 (Retrieval)	장한빈	임베딩·검색 스택 설계, 서빙 화면 프로토타입
생성 (Generation)	김다혜	답변 생성 로직, 인용 형식, 시각 문서 처리

1.2 MVP 범위

- 입찰 공고 탐색
- RFP 근거 질의 (금액·기간·자격요건 등)
- 문서 비교 (다중 문서)
- 근거 부족 시 기권 (hallucination 방지, 전용 평가문항 10개로 검증)

2. 진행 과정

2.1 프로젝트 착수 및 데이터 기반 구축 (8/24 ~ 9/1)

kickoff 직후 가장 먼저 확인한 것은, 제공받은 요약 CSV가 원본 문서 내용의 4.87%만 담고 있다는 사실이었다. 이에 따라 요약본이 아닌 원본 문서(HWP·PDF)를 직접 처리하는 방향으로 전환했다. 중복 문서 2건을 제거해 98건(HWP 94, PDF 4)으로 확정하고 전량 재파싱했으며, 예산·기관명·마감일 등 오류·결측 정보 73건을 원문 대조로 직접 교정했다.

이 시기 데이터 전처리 단계에서도 별도로, pyhwp가 표·이미지를 실제 내용 대신 <표>/<그림> 자리표시자로만 추출하던 문제를 발견했다. 전체 HWP 문서에 영향을 미치는 문제라 제거 로직을

추가하고 캐시를 적용했다. 또한 PDF 표 추출이 본문과 완전히 중복되는 것을 발견해, 대상 PDF 4건의 표 834개를 전수 검사한 결과 완전중복 95%, 부분중복 5%, 고유 정보 0%임을 확인했다. 중복 필터를 넣지 않았다면 임베딩에 순수 노이즈를 쌓고 있었을 상황이었다.

같은 시기 조건(예산·기관·마감일)이 포함된 질문은 벡터 검색만으로 부족하다는 것을 확인해 조건 필터링을 추가했고(정확도 약 15%p 개선), 청크 병합 로직의 버그(토큰 상한 처리 순서 오류로 짧은 청크가 이웃과 병합되지 않던 문제)도 함께 수정했다.

2.2 임베딩·검색 스택 확정 및 중간발표 (9/1 ~ 9/4)

한국어 특화 임베딩 모델(KURE-v1)을 해외 범용 모델 및 유료 API와 비교한 결과, 어려운 질문일수록 격차가 크게 벌어져(Top-5 정확도 73.9% vs 56.9~60.9%, 평균 순위 84.7위 vs 308~319위) KURE-v1을 최종 채택했다. 검색 방식은 의미 기반과 키워드 기반을 0.0~1.0을 0.1 간격으로 전 구간 스윙 실험한 결과, 현재 기본값 0.5(정확히 5:5)가 11개 후보 중 5개 지표 평균 1위로 최적임을 확인했다. 특정 지표만 근소하게 앞서는 값이 있어도 다른 지표에서 더 크게 손해 보는 트레이드오프였다. 문서 재정렬(리랭커) 기능은 시도했으나, 표준 조항 조항 때문에 정답 문서 순위가 1위에서 8위 밖으로 밀리는 사례가 발견되어 채택하지 않았다. 원인은 두 가지로 파악됐다. 필터·집계형 질문이 cross-encoder 구조와 맞지 않는 점, 그리고 RFP 표준 조항은 발주기관만 다르고 문구가 거의 같아 리랭커가 어느 기관 문서인지 구별하지 못해 BM25가 잡던 신호를 오히려 눌러버린 점이다. 답변 문맥은 검색은 작게, 답변 시 문맥은 넓게 확장하는 Parent-Child 구조를 도입했다(context fact coverage: 완전 커버율 36.1%→40.7%, 평균 coverage 45.2%→51.9%. 비용으로 recall@5가 0.982→0.973으로 0.9%p 소폭 하락). 9월 4일 중간발표 시점 검색 성능은 Recall@5 96.4%, MRR 91.1%(공식 111문항 기준), 답변 성능은 평균 89.6점(자체 40문항 기준)이었다.

2.3 중간발표 이후 재진단 (9/7)

중간발표에서 검색 성능이 우수하다고 보고했으나, 이후 더 깊은 분석을 통해 중요한 사실을 추가로 확인했다. 문서 단위 Recall은 97%로 높았지만, 문서 안에서 정확한 세부 조항까지 찾아내는 청크 단위 Recall은 61%에 그쳤다. 원인은 ①문서 개요·표지가 반복 등장해 검색 순위를 차지하는 것과 ②여러 문서에 공통으로 들어가는 표준 조항이 다른 회사 문서에서 잘못 끌려오는 것 두 가지였다. 같은 시기, 기존에 '새 지시문이 모델을 소극적으로 만든다'고 판단했던 기관 문제도 재검토한 결과, 실제 원인은 생성 단계가 아니라 검색이 필요한 정보를 찾지 못한 데 있었다. 또한 검색엔진(FAISS, Chroma) 비교 실험 중 검색 결과가 완전히 동일한데도 최종 점수가

달라지는 현상을 발견했고, 그 원인이 검색엔진이 아니라 생성 모델의 응답 자체가 실행마다 조금씩 달라지는 특성 때문임을 확인했다. 이 발견은 이후 채점 체계 설계에 중요한 전제가 되었다.

2.4 채점 체계 정비 (9/8 ~ 9/10)

여러 실험을 거치며 채점 기준 자체의 신뢰성을 점검할 필요가 확인되어, 채점기를 4단계에 걸쳐 개선했다. v2에서는 실행 오류와 기권을 분리하고 부분 답변을 별도로 분류했다. v3.0.0에서는 조사·어미 표현 차이를 인정하도록 정규화를 도입했으나, 형태소 40% 일치만으로 정답 처리되는 과대채점이 발견되어 즉시 폐기했다. v3.0.1에서는 숫자 일치를 필수 조건으로 추가하고 형태소 일치 기준을 100%로 강화해 재조정했다. 이후 실제 운영 중 발견된 세부 문제(대괄호 포함 문서명이 인용 종료 기호로 오인되는 문제 등)를 반영해 v3.1.2까지 개선을 이어갔다. 이 과정에서 채점 코드 버그 5종을 추가로 발견해 수정했다. 금액 심표 표기, 조사·괄호가 낀 단어 순서, 날짜 표기 차이, 다중 답변을 완전 기권으로 오분류, 인용 파일명이 대괄호에서 잘리는 문제다. 이 중 다중 답변 오분류와 대괄호 문제는 재생성 없이 재채점만으로 각각 8건·6건의 오판을 정정할 수 있었다.

2.5 답변 품질 개선 (9/8 ~ 9/9)

인용 표시 형식이 매번 달라(“근거:”, “근거 문서:”, “출처:” 등) 채점이 되지 않던 문제를 [근거: 문서명] 형식으로 통일했으며, 이때 답변 생성 코드도 최신 버전으로 함께 교체되었다.

목록형 질문(“학교 발주 사업 전부” 등)은 벡터 검색 방식 자체가 부적합함을 재확인했다. 검색 개수(k)를 80에서 200까지 늘려도 유사도가 낮은 정답 문서가 계속 누락되는 것을 확인해, k를 늘리는 방식으로는 해결이 불가능한 구조적 한계로 판단했다. 조건에 맞는 문서를 메타데이터에서 직접 걸러내는 방식으로 전환했다(관련 점수 45점→80점, 정답 수 수정 이후 85.5점). 이 과정에서 긴급·보안·재난 조건이 감지는 되지만 실제 필터링 로직엔 반영되지 않아 사실상 무력화돼 있던 버그도 함께 발견해 수정했다. 문서 힌트 매칭(질문에서 정답 문서를 찾는 로직)에서도 오탐 원인 7가지를 발견해 수정했다. 행정구역 접미사 미차단, 공백 처리 버그, 흔한 사업 용어로 인한 오매칭, 블랙리스트 우회 패턴, 문서 1개뿐인 발주기관의 오매칭, 별칭 딕셔너리 표기 불일치, 그리고 같은 발주기관 내 여러 문서 중 하나를 선택하는 로직이 앞 단계에서 고친 키워드 체크를 놓쳐 오탐이 재발하는 패턴이다. 이 마지막 사례로 “하나의 오탐 원인이 매칭 로직 여러 단계에 걸쳐 있을 수 있다”는 게 이후 디버깅의 기본 전제가 됐다.

그림·도표에만 답이 있는 문항을 위해 이미지 판독 모델(VLM, Qwen3-VL-8B)을 연결해, 그림 문항 평균 점수를 0~20점대에서 100점으로 끌어올렸다. 다만 이 실험은 정답 이미지 위치를 미리 알려준 조건에서 진행된 것으로, 질문만으로 정답 이미지를 스스로 찾아내는 완전한 시각 검색까지 검증된 것은 아니다.

2.6 재현성 검증 및 안정화 (9/10)

동일 조건으로 반복 실행한 결과, 점수가 소폭(1점 내외) 흔들리는 현상을 확인했다. 이는 코드나 설정의 문제가 아니라 생성 모델이 매 실행마다 조금씩 다르게 응답하는 특성 때문으로 확인됐다. 인용 형식 통과율도 동일한 이유로 100%에서 95% 수준으로 흔들렸으며, 원인은 근거 표시([근거: ...]) 뒤에 모델이 부가 설명을 덧붙이는 경우였다. 채점기가 근거 표시를 답변의 마지막 줄로 인식하는 구조라, 이 경우 인용 형식 실패로 처리됐다. 이는 채점 기준을 느슨하게 바꾸는 대신, 보완 문구를 근거 블록보다 항상 앞에 삽입하도록 답변 생성 후처리 로직을 수정해 해결했다. 근거 표시가 항상 답변의 마지막 줄에 오도록 고정한 것으로, 재검증에서 정상 작동이 확인되었다. 같은 시기 낮은 점수 문항을 재조사하는 과정에서, 반복적으로 특정 세부 항목을 빠뜨리는 패턴도 다수 확인했다. 프롬프트 지시("나열된 항목을 모두 언급하라")나 LLM 자체 재검토로는 재현성 있게 해결되지 않았으나, 컨텍스트에 정보가 실제로 있는지 코드로 직접 확인해 결정론적으로 보완 문구를 추가하는 후처리 규칙으로 전환해 해결했다. 이 방식을 표현이 매번 달라지는 동의어 케이스와 표 구조 소실로 항목-점수 매핑 자체가 틀리는 케이스까지 확장 적용했다. "100분의 N"과 "N%", "N점"과 "N%"처럼 법률식·백분율·점수 표기를 LLM이 매번 다르게 오가는 재현성 문제도, 원문을 지우지 않고 옆에 환산값을 병기하는 정규화로 결정론적으로 해결했다.

또한 파일명에 포함된 대괄호 등 특수문자가 로깅 과정에서 잘못 처리되어, 정상적으로 검색된 문항도 '검색 실패'로 잘못 기록되는 버그를 새로 발견했다. 이로 인해 이전까지 보고된 일부 검색 성능 수치는 재계산이 필요하다.

2.7 로컬 모델 실험 및 서빙 프로토타입 (9/8 ~ 9/10)

유료 API에 대한 의존을 낮추기 위해 로컬 환경에서 구동 가능한 모델(Qwen3-8B) 실험을 병행했다. 검색 성능은 API 방식과 비슷했으나(문서 Recall 98%), 답변 생성 단계에서 출력 형식 오류가 다수 발생해 안정화 작업을 진행했다. 이와 함께 기존의 복잡한 반복 실행 구조 대신, 실제 서비스에 필요한 고정 실행 경로만 분리한 경량 실행 구조(hotline-runtime)를 별도로 정리했다 — 자동 재시도·자동 재색인을 제거하고 실행시간을 120초로 제한하며, 범위를 벗어난 근거나 오류는 안전하게 실패 처리(fail-closed)하도록 설계했다. 다만 이 구조의 자동 검증 테스트 통과는

코드가 설계대로 안전하게 동작한다는 의미이며, 모델 답변의 정확도가 향상되었다는 의미는 아니다. 사용자가 실제로 쓸 수 있는 서빙 화면도 제작했다. 먼저 자주 묻는 질문 후보 추출기 11종을 만들었다. 골든셋 문항을 주제별로 훑어 빈도 순으로 항목을 선정했다(하도급·공동수급 15건, 사업목적 13건, 평가배점 9건, 계약방식 8건, 참가자격 8건, 보증금 6건 등: 예산/일정, 발주 기관, 첨부 서식 목록, 제안서 작성 규정, 하도급/공동수급, 사업목적 요약, 계약 방식, 참가 자격, 계약 보증금, 문의처, 평가배점(참고용)). 전체 코퍼스 기준 항목별 후보 발견율은 하도급·사업목적 99~100%, 참가자격 98%, 문의처 90%, 평가배점 89%, 계약방식 88%, 신청서식 85~87%였다. 계약보증금은 초기 발견율이 낮았으나 세 차례 개선(분수 표기, 줄바꿈이 낀 경우, 천분율·전각 % 인식)으로 22.4%→43.9%까지 끌어올렸고, 남은 미검출 건은 원문을 직접 확인한 결과 문서 자체에 비율이 적혀 있지 않은 표준 서식이라 정규식의 한계가 아님을 확인했다.

웹 앱은 FastAPI 백엔드와 순수 HTML/JS 화면으로 프로토타입까지 구현했다. 문서를 고르면 버튼 11종으로 후보를 확인하고, 선택적으로 LLM 요약을 받고, 그 문서 범위의 자유 질문(기존 Hybrid 검색 재사용)도 할 수 있도록 설계했다. 대화 상태를 서버가 아닌 브라우저가 들고 있어 여러 명이 동시에 접속해도 화면이 섞이지 않는 구조이며, 무거운 자산은 지연 로드 방식이라 버튼만 쓰면 2.2GB 임베딩 모델을 아예 올리지 않는다.

다만 이 프로토타입을 팀 통합 파이프라인과 연동해 실제 서버에 배포하는 작업은 완료하지 못했다. 상세 계획은 6.1절 참고.

2.8 통합 생성 모델 최종 실험 (9/10)

검색·생성·인용·채점을 하나의 흐름으로 연결한 통합 파이프라인에 대해 Golden Set v3(79문항) 기준으로 최종 측정을 수행했다. 측정 조건은 아래와 같다.

항목	값
평가셋	Golden Set v3, 79문항
검색 구성	KURE-v1 임베딩 + BM25 Hybrid (ChromaDB)
생성 모델	GPT-5-mini
시각 근거	Qwen3-VL-8B-Instruct, 검증된 기존 4건 재사용
채점기 버전	v3.1.2
실행 오류	0건

지표	값
----	---

End-to-End 점수	88.84
검색 Recall	93.04%
Context 사실 포함률	90.41%
인용 형식 통과율	100%
Set형 질문 Macro F1	85.53%
Set형 질문 완전 일치율	69.23%

주의 88.84점은 의미를 이해하는 LLM Judge 점수가 아니라, 채점기 v3.1.2의 결정론적(사실·형식 일치 기반) End-to-End 점수다. 의미적 정확성과 근거 충실도는 별도의 LLM Judge 또는 사람 검수가 추가로 필요하다.

Set형(여러 문서를 찾아야 하는) 질문은 Recall 100%로 필요한 문서를 모두 찾아내지만, 불필요한 문서도 함께 반환해 Precision(80.77%)과 완전 일치율이 상대적으로 낮게 나타났다.

2.9 최신 재검증 — 생성 코드 4b0327a (9/10)

2.8절 실험(생성 코드 4a19d50 기준) 이후, 표기 보완과 생성 후처리를 반영한 다음 버전(4b0327a)으로 동일 조건 재실험을 진행했다. 실험 구성은 평가 문항 79개, 생성 모델 gpt-5-mini, 채점기 v3.1.2, VLM은 기존 Qwen3-VL 근거 4건 재사용, 실행 오류 0건으로 2.8절과 동일하며, 생성 코드만 4a19d50 → 4b0327a로 교체했다.

주의 이번 VLM 결과 역시 Blind Visual Retrieval(질문만으로 정답 이미지를 스스로 찾는) 평가가 아니다 — 2.5절과 동일하게 정답 위치가 미리 주어진 조건의 결과다.

지표	4a19d50	4b0327a	변화
End-to-End	88.84	89.54	+0.70%p
어휘 사실 점수	89.17	90.03	+0.86%p
검색 Recall	93.04%	93.04%	동일
Context 사실 포함률	90.41%	91.22%	+0.81%p
기권 일치율	93.94%	93.94%	동일
인용 형식 통과율	100%	100%	동일
인용 Recall/Precision	93.04%	92.88%	-0.16%p

Set Macro F1	85.53%	85.53%	동일
시각 문항 점수	85.00	100.00	+15.00%p

주요 변화

- 정상 답변 67건 → 70건, 부분 답변 6건 → 3건으로 감소
- 시각 문항 10건 평균 85점 → 100점으로 개선
- 검색 성능과 Set 성능은 이전과 동일 — 이번 개선은 검색 단계가 아니라 생성 후처리·표기 보완에서 발생한 것으로 판단됨
- “100분의 N ↔ N%” 등 점수·백분율 표기 정규화, 누락되던 키워드·신인도 가점표 후처리가 반영됨

주의 인용 형식은 79건 모두 통과했지만, 인용 내용 Recall·Precision은 0.16%p 하락했고 근거로 뒷받침되지 않는 인용(unsupported citation)도 1건에서 2건으로 늘었다. 이는 VLM이 생성한 내부 근거 ID가 문서명 대신 최종 인용에 섞여 들어가는 것으로 확인됐다. 생성 파이프라인(Generation) 쪽 프롬프트·코드에는 VLM이나 근거 ID 관련 로직이 없음을 확인해, 형식이 아니라 VLM 결과를 컨텍스트에 주입하는 단계의 문제로 판단하고 있다. 후속 확인이 필요하다.

최종 생성 코드 4b0327a는 이전 버전 대비 End-to-End 점수가 0.70%p 상승한 89.54점을 기록했다. 특히 시각 문항 점수가 100점으로 개선되고 부분 답변도 줄었다. 다만 이는 단일 실행 결과이므로, 이 개선 폭 전체를 코드 변경의 효과로 확정하려면 2.6절에서 확인된 재현성 원칙에 따라 반복 실행 검증이 필요하다.

3. 최종 아키텍처

HWP/PDF 문서 → 텍스트·표·이미지(OCR 포함) 추출 → Parent-Child 청킹 → KURE-v1 임베딩 + BM25 키워드 검색의 Hybrid 검색 → 근거 문서 선별 → GPT-5-mini(또는 로컬 Qwen) 기반 답변 생성 → 문서명 기반 인용 생성 및 자동 채점의 순서로 구성된다.

- 임베딩: 한국어 특화 모델(KURE-v1) — 유료 API 대비 우위 확인 후 채택
- 검색: 의미 기반 + 키워드 기반을 5:5로 결합한 Hybrid 검색, 조건형 질문은 메타데이터 직접 필터링
- 청킹: 검색은 작은 단위(child), 답변 문맥은 넓은 단위(parent)로 확장
- 시각 문서: 그림 문항은 별도 VLM(Qwen3-VL-8B)으로 판독해 답변에 반영
- 생성: gpt-5-mini 기반, 근거 부족 시 기권하도록 설계, 로컬 모델(Qwen3-8B) 대안 실험 진행 중
- 서빙: FastAPI + HTML/JS 웹 앱, 자주 묻는 질문 버튼 11종

4. 주요 성과 요약

구분	지표	결과
검색 (중간발표 시점)	Recall@5 / MRR (공식 111문항)	96.4% / 91.1%
채점 체계 정비	통합 시스템 점수 (v3.0.1)	70.1점
인용 형식 통일 + 생성코드 교체	통합 시스템 점수	82.3점
그림 인식(VLM) 통합	통합 시스템 점수 / 그림 문항 평균	85.4점 / 100점
재현성 검증 + 채점기 v3.1.2	통합 시스템 End-to-End 점수	88.84점
최신 생성 코드 재검증 (4b0327a)	통합 시스템 End-to-End 점수	89.54점
목록형(Set) 질문	Macro F1	45% → 85.5%
서빙 프로토타입	보증금 비율 추출 정확도	22% → 44%
로컬 모델 검색	문서 Recall	약 98%

주의 표의 각 행은 서로 다른 시점·채점기 버전·생성 코드에서 측정된 값이며, 평가셋 규모도 서로 다르다(공식 111문항, 자체 40문항, rag-56 54문항, Golden Set v3 79문항 등 담당자·시점별로 검증에 사용한 골든셋이 상이함). 시계열 비교는 참고용이며, 공식 성능으로는 가장 최신 조건(2.9절, 89.54점, Golden Set v3 79문항 기준)의 값을 기준으로 한다. 단, 이 값은 단일 실행 결과로 반복 검증이 아직 진행 전이다.

5. 개선 사항 상세 — 발견한 문제와 해결 조치

문제	원인	해결 조치
조건형 질문(예산·기관·마감일) 정확도 낮음	벡터 검색만으로는 조건 판단 불가	조건 사전 필터링 추가 (정확도 약 15%p 개선)
pyhwp가 표·이미지를 자리표시자로만 추출	파서 한계	자리표시자 제거 로직 추가, 캐시 재적용
짧은 청크가 이웃과 병합되지 않음	병합 로직의 토큰 상한 처리 순서 오류	병합 로직 수정
리랭커 적용 시 정답 순위 하락	여러 문서에 공통된 표준 조항으로 인한 혼동	리랭커 미채택
문서 단위 검색은 정확하나 세부 조항 검색은 부정확	개요·표지 청크의 순위 과대평가, 표준 조항의 교차 혼입	원인 특정, 코드 수정은 진행 중
기관 판단 오류로 추정했던 문제	실제로는 검색이 근거를 찾지 못한 것	원인 재규명, 검색 단계 문제로 재분류
검색엔진 비교 시 점수 불일치	생성 모델의 실행별 응답 변동	재현성 검증 절차 도입, 기능이 더 갖춰진 엔진으로 통합
채점기 과대채점 (v3.0.0)	형태소 40% 일치만으로 정답 인정	즉시 폐기, 100% 일치 기준으로 재수정
기관 정답 문항이 채점에서 누락	필수 사실 0개 문항의 0/0 나눗셈 처리 오류	별도 로직으로 처리하도록 수정
인용 형식 채점 실패	근거 표시 형식이 매번 다르게 출력됨	[근거: 문서명] 형식으로 통일
목록형 질문 정답 누락	벡터 유사도 기반 검색이 조건 매칭에 부적합	메타데이터 직접 필터링으로 전환

긴급·보안·재난 조건 필터가 실제로는 무력화	조건 감지는 되나 필터링 로직에 반영 안 됨	파일명 기준 실제 필터링 로직 추가
그림 문항 답변 불가	이미지 정보가 텍스트로 추출되지 않음	VLM(Qwen3-VL-8B) 연동
대괄호 포함 문서명 처리 오류	대괄호를 인용 종료 기호로 오인식	인용 파싱 로직 수정 (v3.1.2)
검색 로그 오기록	특수문자 포함 파일명이 로깅 과정에서 잘림	발견, 재계산 필요 (수정 진행 중)
인용 형식 통과율 재현성 흔들림(100%→95%)	근거 표시 뒤에 모델이 부가 설명을 덧붙임	보완 문구를 근거 블록보다 앞에 삽입하도록 수정, 근거를 항상 마지막 줄로 고정
특정 세부 항목을 반복적으로 빠뜨림	LLM이 긴 목록 중 일부를 생성 시마다 다르게 누락	컨텍스트 대조 기반 결정론적 보완 후처리 도입
법률식·백분율·점수 표기가 실행마다 다르게 생성됨	LLM 생성 변동성	원문 표기를 지우지 않고 환산값을 병기하는 정규화 적용

6. 남은 과제 및 향후 계획

6.1 기술적 과제

- 대괄호 파일명 로깅 버그 수정 후 검색 성능 수치 전체 재계산
- 문서는 찾지만 세부 조항을 못 찾는 청크 단위 검색 격차 개선 착수
- 목록형(Set) 질문 채점 방식의 정답 개수 사전 노출 구조를 실제 서비스 조건으로 수정
- 최신 생성 코드(4b0327a)의 인용 Recall·Precision 하락 및 unsupported citation 증가 원인 확인
- 생성 코드 4b0327a의 End-to-End 개선폭(+0.70%p)을 반복 실행으로 재현성 검증
- 질문만으로 정답 그림·표를 스스로 찾아내는 자동 시각 검색(visual retriever) 구현 — 현재까지는 Blind Visual Retrieval 평가가 아님
- 의미 기반(LLM Judge) 채점 도입 — 현재는 결정론적 채점만 진행 중
- 로컬 모델(Qwen3-8B) 출력 형식 오류 수정 및 전체 문항 재실행

- 서버 웹 앱(FastAPI + HTML/JS)을 팀 통합 파이프라인과 연동해 GCP VM에 배포. CPU 전용 도커 이미지로 계획 중이며(서버리스는 “모델을 한 번 올려두고 재사용”하는 구조와 안 맞아 제외), 데이터·모델 캐시는 호스트 볼륨 마운트로 구성해 재빌드 시 인덱스를 다시 만들지 않도록 설계함. 통합·배포는 완료하지 못해 다음 단계로 이월.

6.2 팀 확인이 필요한 사항

- "통합 시스템 점수"의 공식 기준(평가셋·채점기 버전) 확정
- 골든셋(시험문제) 정답 수정 사항에 대한 팀 승인
- 서비스 배포 방식(FastAPI+Docker 등) 및 다중 모델 지원 여부 결정

7. 결론

이번 프로젝트를 관통하는 발견은 “겉보기 지표가 좋아 보여도, 더 깊이 파고들면 다른 그림이 나온다”는 패턴이 검색·채점·재현성 등 여러 영역에서 반복적으로 확인되었다는 점이다. 중간발표 시점의 우수한 검색 성능 지표는 청크 단위 분석에서 한계가 드러났고, 채점기 개선 과정에서도 과대채점을 자체적으로 발견해 폐기하는 등, 숫자 자체보다 그 숫자가 왜 그렇게 나왔는지 끝까지 추적하는 과정을 프로젝트 전반의 원칙으로 삼았다.

현재 통합 파이프라인은 검색·생성·인용·채점이 하나의 흐름으로 연결되어 동작하고 측정 가능한 상태에 도달했다(End-to-End 89.54점, Golden Set v3 79문항, 채점기 v3.1.2, 생성 코드 4b0327a 기준). 다만 이는 결정론적 채점 기준의 단일 실행 결과이며, 반복 실행을 통한 재현성 검증, 시각 검색 자동화, 표 구조 이해, 인용 내용의 정확성 확인, 의미 기반 채점 등은 다음 단계의 고도화 과제로 남아 있다.